UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE COMPUTAÇÃO
CIÊNCIA DE DADOS II

Arthur Aquino Guardieiro
Guilherme Antonio Garcia do Nascimento
Rodrigo Martins de Souza

# Agrupamento de Boletins de Ocorrência Utilizando Algoritmos de Clusterização

Uberlândia
2026

# Sumário

**1 Introdução** **2**

**2 Descrição dos Dados** **2**

**3 Metodologia** **3**

**4 Resultados** **4**

4.1 Heatmaps Para Crimes . . . . . 4

4.2 Uso de Arma de Fogo . . . . . 6

4.3 Crimes Violentos e Tipo de Local . . . . . 7

4.4 Agrupamento de tipos de crimes por perfis temporais . . . . . 8

**5 Discussões e Conclusões** **9**

**6 Referências** **9**

# 1 Introdução

A análise de dados públicos tem se consolidado como ferramenta relevante para compreender fenômenos sociais complexos, como a criminalidade. No contexto da segurança pública, os boletins de ocorrência reúnem informações sobre natureza do delito, local, data, horário e características do fato, permitindo investigar padrões que não são facilmente percebidos por inspeção manual.

Neste trabalho, utiliza-se uma abordagem de ciência de dados com técnicas de análise exploratória, testes estatísticos e aprendizado não supervisionado para estudar registros de Minas Gerais disponibilizados no Portal de Dados Abertos. A proposta está organizada em três eixos: identificação de padrões temporais e espaciais gerais das ocorrências; análise da concentração de ocorrências com arma de fogo por período e por região; e avaliação da associação entre tipo de local e crimes violentos.

A estrutura do relatório segue o pipeline implementado no notebook: descrição da base, pré-processamento, análise exploratória, modelagem por clusterização, validações estatísticas e interpretação dos resultados.

# 2 Descrição dos Dados

Os dados utilizados neste relatório foram obtidos no Portal de Dados Abertos do Estado de Minas Gerais, que disponibiliza à sociedade registros oficiais de boletins de ocorrência. A base analisada reúne informações estruturadas sobre criminalidade em diferentes municípios do estado, permitindo análises com recortes temporal, espacial e temático.

A unidade de análise do conjunto não corresponde a ocorrências individuais, mas a registros agregados. Esse caráter agregado é representado pela variável *qtde_ocorrencias*, que indica o total de boletins associados a uma determinada combinação de atributos. Assim, cada linha da base representa um agrupamento de ocorrências com características comuns.

Para aprofundar a investigação, foram construídas variáveis indicadoras derivadas dos dados originais. A variável *usa_arma_fogo* foi definida de forma binária a partir de busca textual em *descricao_longa_meio_utilizado*, identificando menções a arma de fogo. Já a variável *crime_violento* também foi construída de forma binária com base em padrões textuais de *natureza_principal_completa*, incluindo categorias como homicídio, roubo, latrocínio, estupro, lesão corporal, sequestro e extorsão.

Como a base é agregada, as proporções e medidas de associação foram calculadas de forma ponderada por *qtde_ocorrencias*, de modo a refletir a frequência real dos eventos. Predominam variáveis categóricas no conjunto de dados; por isso, foram empregadas técnicas de análise de frequência, clusterização não supervisionada (K-Means), testes de independência (qui-quadrado), medidas de associação (V de Cramér) e métricas de diversidade (entropia), com o objetivo de identificar padrões estruturais espaço-temporais da criminalidade.

# 3 Metodologia

A metodologia aplicada neste trabalho foi estruturada em um fluxo de preparação, modelagem e validação dos dados. Na etapa de pré-processamento, os arquivos foram integrados em um único conjunto de dados, com padronização das colunas e remoção de variáveis irrelevantes. A variável temporal referente à data da ocorrência foi tratada para garantir consistência de formato e permitir análises cronológicas. Também foi criada a variável categórica faixa horária, derivada da informação de horário da ocorrência, classificando os registros em Madrugada, Manhã, Tarde e Noite.

Na análise exploratória foi considerada a quantidade de ocorrências associada a cada registro, permitindo estimativas ponderadas e evitando distorções decorrentes de simples contagem de linhas. Foram construídas tabelas e visualizações relacionando dia da semana e faixa horária, incluindo heatmaps em escala absoluta e proporcional. Também foram criadas variáveis derivadas para identificar ocorrências com uso de arma de fogo e para classificar crimes violentos, possibilitando aprofundar a análise temática dos dados.

A análise exploratória combinou estatísticas descritivas, análise da distribuição do volume de ocorrências por meio de histogramas e boxplots, heatmaps de volume e proporção por dia da semana e faixa horária, além de matrizes de correlação de Pearson e Spearman para as variáveis numéricas disponíveis.

Na etapa de modelagem foi construída uma matriz de perfis temporais de criminalidade a partir da agregação das ocorrências por natureza do crime (natureza_principal_completa) e faixa horária. Cada tipo de crime foi representado por um vetor contendo a distribuição proporcional de ocorrências ao longo das faixas horárias. A partir dessa matriz foram aplicados algoritmos de clusterização não supervisionada com o objetivo de identificar grupos de crimes com padrões temporais semelhantes.A interpretação dos resultados foi realizada por meio da análise dos perfis médios de cada cluster e da identificação dos tipos de crimes mais representativos de cada agrupamento.

Foram testados diferentes algoritmos de agrupamento não supervisionado, incluindo K-Means, agrupamento hierárquico e DBSCAN. A comparação foi realizada utilizando métricas internas de avaliação de clusters, como Silhouette Score, Davies-Bouldin e Calinski-Harabasz. Entre os métodos testados, o K-Means apresentou melhor equilíbrio entre separação dos grupos e interpretabilidade dos resultados, sendo adotado como modelo final com k = 3.

Por fim, as associações entre variáveis categóricas foram avaliadas por meio de tabelas de contingência ponderadas pela quantidade de ocorrências (qtde ocorrencias). A partir dessas tabelas foi aplicado o teste qui-quadrado de independência, seguido do cálculo da medida de magnitude de efeito V de Cramér, permitindo avaliar a intensidade da associação entre as variáveis analisadas..

# 4 Resultados

## 4.1 Heatmaps Para Crimes

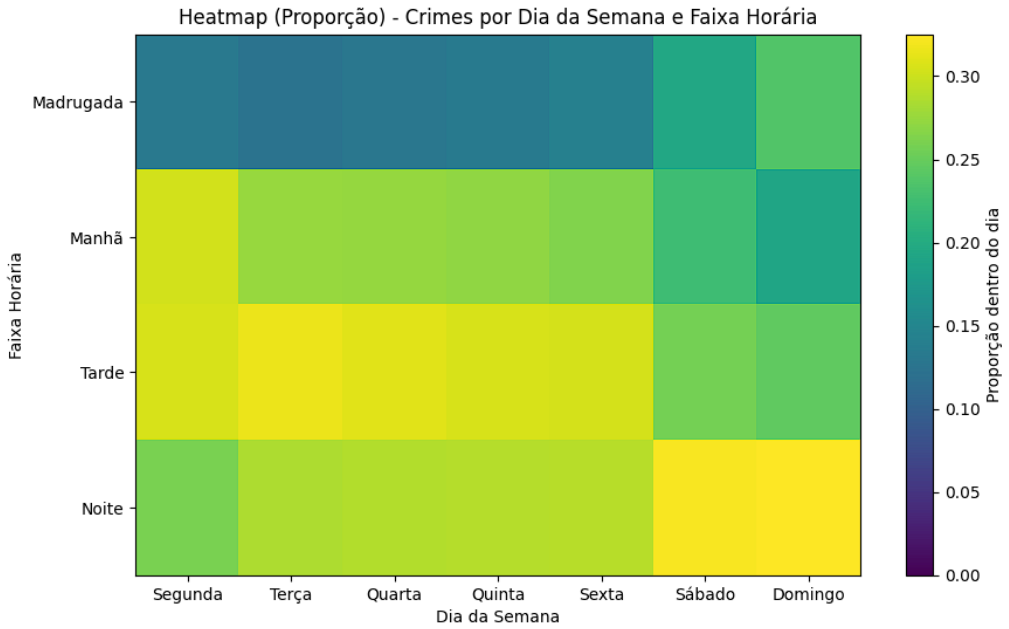


Figura 1: Distribuição proporcional das ocorrências por faixa horária dentro de cada dia da semana, ponderada por quantidade de ocorrências.

A Figura 1 apresenta a distribuição proporcional das ocorrências ao longo das faixas horárias. É possível observar predominância do período da tarde durante os dias úteis, enquanto nos finais de semana há aumento da participação relativa do período noturno. Isso indica que o padrão temporal da criminalidade geral varia conforme o dia da semana, acompanhando a dinâmica social e urbana.

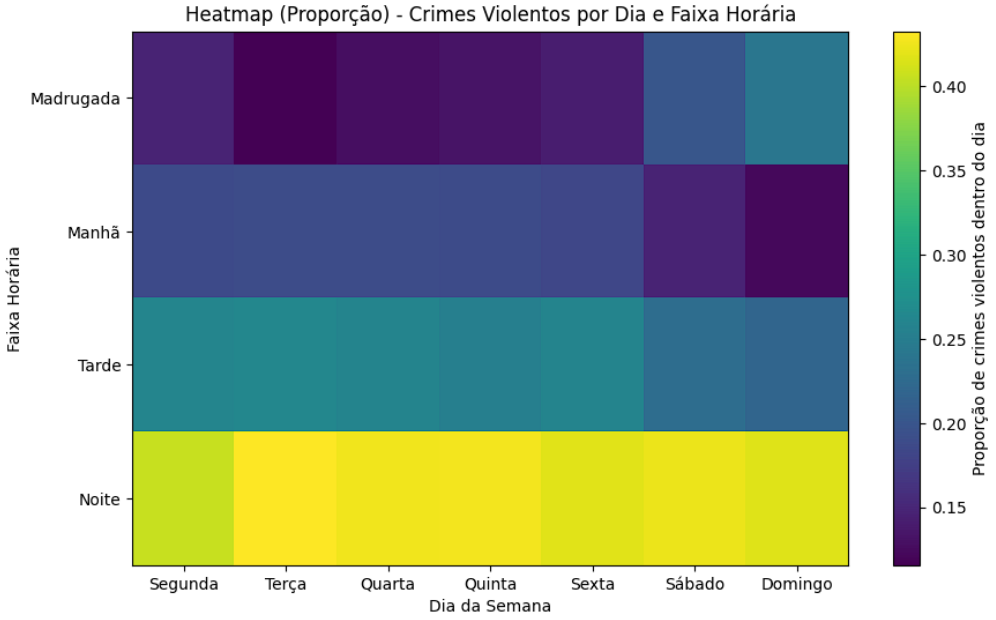


Figura 2: Distribuição proporcional de crimes classificados como violentos por faixa horária e dia da semana.

A Figura 2 mostra a distribuição proporcional dos crimes violentos por faixa horária e dia da semana. Os crimes violentos apresentam concentração consistente no período noturno ao longo de toda a semana. Diferentemente do padrão geral, a violência apresenta perfil temporal mais restrito, com predominância noturna inclusive em dias úteis.

## 4.2 Uso de Arma de Fogo

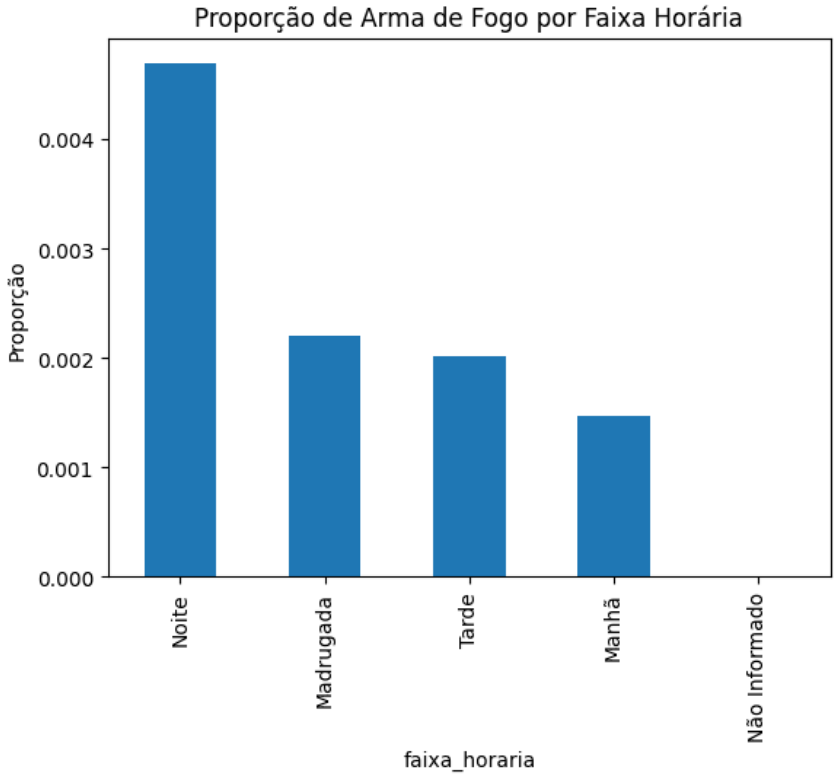


Figura 3: Proporção do uso de Arma de Fogo por Faixa Horária.

A Figura 3 apresenta a distribuição proporcional de ocorrências com uso de arma de fogo por faixa horária, evidenciando maior incidência nos períodos noturnos.

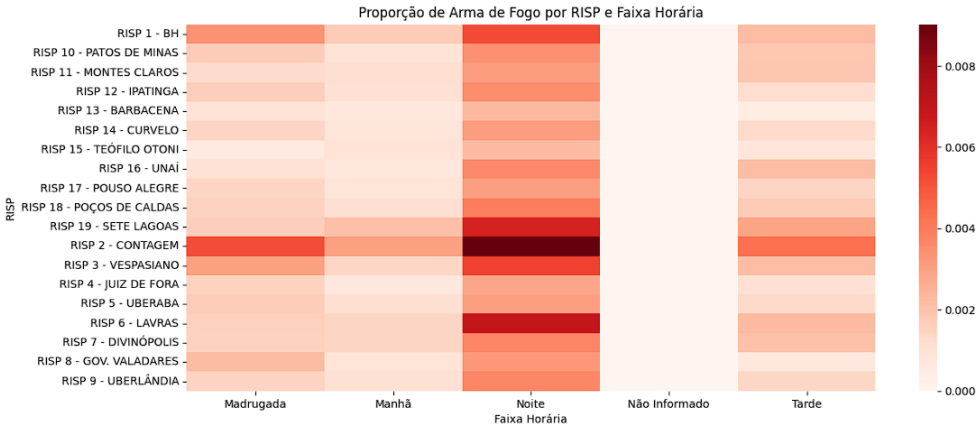


Figura 4: Participação de ocorrências com arma de fogo por RISP e faixa horária.

A Figura 4 apresenta a participação de ocorrências com arma de fogo por RISP e faixa horária. Observa-se variação regional, sugerindo padrões territoriais distintos na distribuição desse tipo de ocorrência.

## 4.3 Crimes Violentos e Tipo de Local

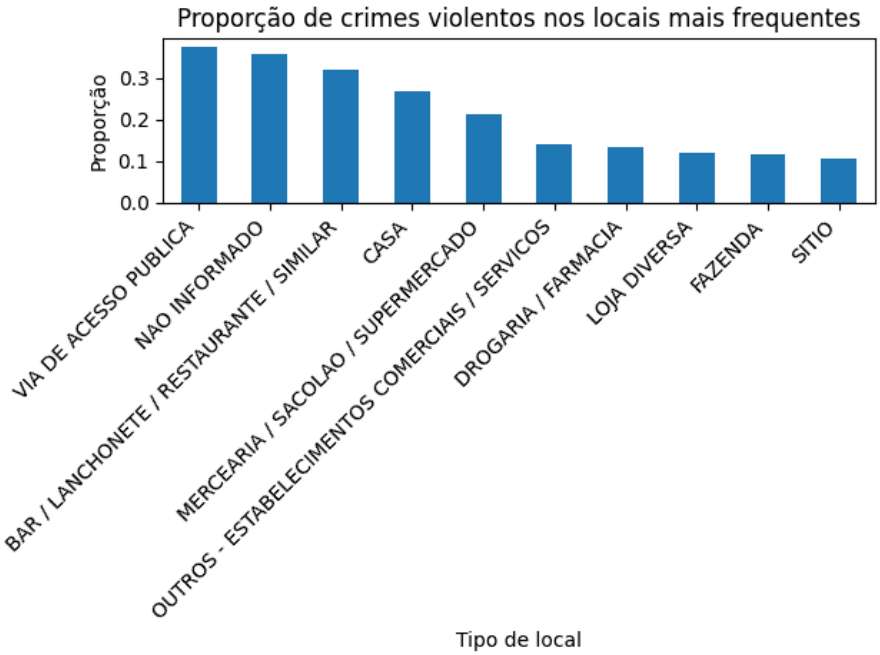


Figura 5: Proporção de crimes violentos nos tipos de local mais frequentes.

A Figura 5 mostra a proporção de crimes classificados como violentos varia significativamente entre os tipos de local, indicando associação entre o ambiente da ocorrência e a gravidade do crime.

## 4.4 Agrupamento de tipos de crimes por perfis temporais

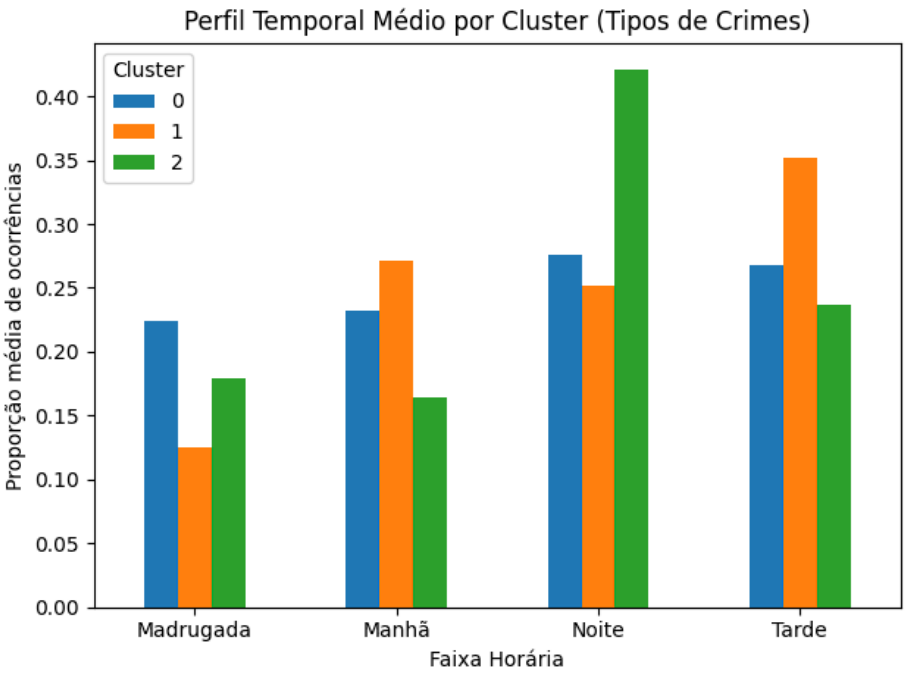


Figura 6: Perfil temporal médio dos clusters de tipos de crimes.

A Figura 6 apresenta a distribuição dos tipos de crimes entre os clusters identificados. Cada agrupamento reúne naturezas criminais que apresentam padrões temporais semelhantes ao longo das faixas horárias analisadas. Essa estrutura indica que diferentes tipos de crimes tendem a ocorrer em períodos distintos do dia, revelando perfis temporais característicos.

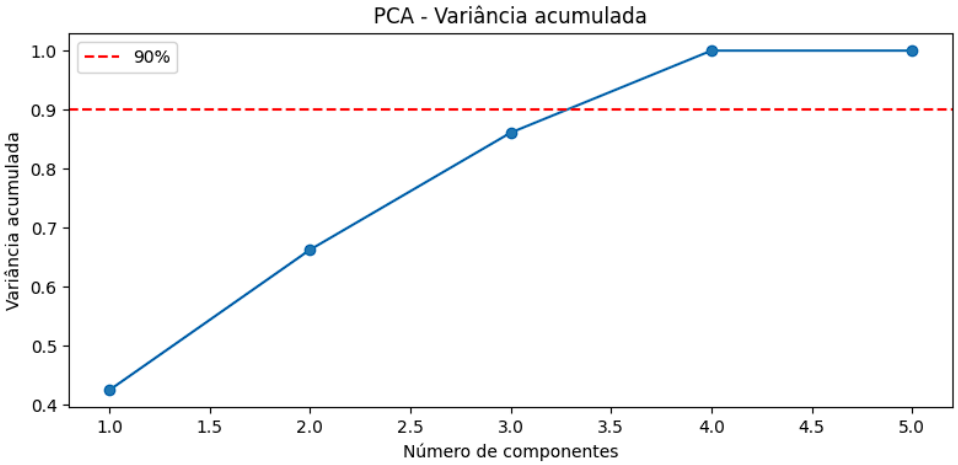


Figura 7: Variância explicada acumulada pelos componentes principais.

A Figura 7 apresenta a variância explicada acumulada pelos componentes principais. O gráfico é utilizado como evidência complementar de estrutura nos dados e como suporte à robustez da etapa de modelagem.

# 5 Discussões e Conclusões

Os resultados obtidos neste trabalho indicam que a dinâmica da criminalidade apresenta padrões estruturais associados a dimensões temporais e espaciais. A análise exploratória feita utilizando a variável *qtde_ocorrencias* permitiu identificar diferenças na distribuição das ocorrências ao longo dos dias da semana e das faixas de horário.

Os heatmaps mostraram que, no conjunto geral de crimes, há predominância relativa de registros no período da tarde durante os dias úteis, enquanto em finais de semana ocorre aumento das participações do período noturno, indicando variações temporais associadas à dinâmica dinâmica social das atividades urbanas. Para os crimes violentos, observou-se um padrão diferente, com alta concentração no período noturno ao longo de praticamente toda a semana, evidenciando que esse tipo de ocorrência apresenta um perfil temporal mais restrito.

A análise do uso de arma de fogo indicou maior participação relativa no período noturno e variações entre as Regiões Integradas de Segurança Pública (RISP), evidenciando diferenças territoriais na incidência desse tipo de evento. Além disso, a avaliação entre tipo de local e crimes violentos revelou que determinados ambientes apresentam participação proporcionalmente maior nesses eventos. A etapa de clusterização dos tipos de crimes revelou a existência de perfis temporais distintos de ocorrência, indicando que diferentes naturezas criminais apresentam padrões característicos ao longo das faixas horárias.

A natureza agregada da base de dados e a construção de algumas variáveis a partir de regras textuais foram limitações, mas ainda assim, os resultados demonstram o potencial de técnicas de análise exploratória e aprendizado não supervisionado para identificar padrões relevantes em dados de segurança pública.

# 6 Referências

MINAS GERAIS. Secretaria de Estado de Justiça e Segurança Pública. Dados abertos da segurança pública. Disponível em: <https://www.seguranca.mg.gov.br/index.php/transparencia/dados-abertos>. Acesso em: 8 mar. 2026.

ZANCHETTA, Marcelo. Notebooks didáticos de Ciência de Dados II. Material de aula disponibilizado durante a disciplina. Universidade Federal de Uberlândia, Uberlândia, 2026.